

Caracterización Morfológica de Granos de Café para SenecaféAlpes

Ana María Hernández Lasso
Juan Sebastián Ardila López
William Andrés Bayona Vergara

Grupo 23



El problema

SenecaféAlpes enfrenta el desafío de la heterogeneidad en sus granos, lo cual impacta la calidad final. Nuestro objetivo es **usar analítica para encontrar patrones morfológicos**.

- Control de Calidad: Estandarizar la selección y clasificación.
- Optimización de Mercado: Diseñar nuevas mezclas de valor.
- Innovación en Trazabilidad: Automatizar la identificación de variedades.



Entendimiento de los Datos

Calidad de los Datos

Se utilizó un conjunto de datos llamado que contiene **14,291** registros y 19 columnas.

Observaciones Iniciales

- Se encontraron **inconsistencias en las variables** categóricas, con valores como "Alargado" y "alargado" que, aunque significan lo mismo, están representados de manera diferente.
- Se identificaron **valores atípicos y negativos** en las variables numéricas, lo cual no es físicamente posible para medidas como el área o el perímetro, indicando posibles errores en la toma de datos.

Variables Numericas

Area, Perimetro, LongitudEjeMayor, LongitudEjeMenor, Excentricidad, AreaConvexa, DiametroEquivalente, Medida, Solidez, Redondez, Compacidad, y los cuatro FactorForma.

Variables Categóricas

ID, RelacionAspecto, DefectoVisible, MétodoSecado.

Entendimiento de los Datos



Para asegurar la calidad del análisis, se realizaron los siguientes pasos de limpieza:


- **Manejo de Valores Atípicos y Negativos:** Se reemplazaron los valores negativos en las variables numéricas con la mediana de cada columna respectiva, y se eliminaron los valores atípicos utilizando el método del rango intercuartílico (IQR).
- **Imputación de Valores Faltantes:** Los valores nulos en las variables numéricas se rellenaron con la mediana, mientras que en las variables categóricas se utilizaron diversas estrategias, incluyendo el relleno con la moda.
- **Eliminación de Duplicados:** Se eliminaron las filas duplicadas basadas en el ID del grano.
- **Estandarización de Variables Categóricas:** Se unificaron las etiquetas en las variables categóricas para corregir inconsistencias (ej. "alargado" y "Alargado" se convirtieron en "Alargado").

Entendimiento de los Datos

Algoritmos de Agrupación

Se implementaron tres algoritmos de clustering:

- **K-Means:** Se utilizó el método del codo y el puntaje de silueta para determinar que el número óptimo de clusters era 2.
- **DBSCAN:** Se experimentó con diferentes valores para los hiperparámetros `eps` y `min_samples`.
- **Modelos de Mezcla Gaussiana (GMM):** Al igual que con K-Means, se determinó que 2 era el número óptimo de componentes.



Modelado

Se evaluaron 3 modelos distintos y se compararon sus métricas:

Modelo	Puntaje Silueta	Calinski-Harabasz	Davies-Bouldin
K-Means	0.32	4467.46	1.23
GMM	0.20	2111.85	1.76
DBSCAN	0.36	38.25	0.51

Puntaje de Silueta: Mide qué tan similar es un objeto a su propio clúster en comparación con otros clústeres. Un valor más alto indica una mejor definición de los clústeres.

Índice de Calinski-Harabasz: Calcula la relación entre la dispersión entre clústeres y la dispersión intra-clúster. Un valor más alto indica una mejor separación.

Índice de Davies-Bouldin: Mide la similitud promedio entre cada clúster y su clúster más similar. Un valor más bajo indica una mejor separación.

Modelo Ganador: ¿Por qué DBSCAN?

DBSCAN demostró ser el algoritmo más efectivo para comprender la estructura natural de los datos, superando a K-Means y GMM en las métricas clave de calidad de clúster.

- **Métricas Superiores:** Obtuvo los mejores indicadores de calidad de clúster (Silhouette 0.363, Davies-Bouldin 0.517).
- **Representación Fiel:** Reveló la estructura natural de los datos (un clúster principal + ruido) en lugar de forzar una división en dos grupos.
- **Conclusión Fiable:** Proporciona un análisis más preciso al no imponer suposiciones artificiales sobre los datos.



Conclusiones

El análisis revela una alta homogeneidad, no una división natural en dos grupos.

- El descubrimiento más valioso no es una segmentación, sino la confirmación de que la muestra de granos es extremadamente cohesiva y uniforme, **formando un único clúster masivo**.
- DBSCAN es el más adecuado porque sus métricas de calidad fueron superiores (Silhouette y Davies-Bouldin) y, lo más importante, identificó la estructura natural de los datos sin forzar una división artificial.
- La homogeneidad detectada es un activo estratégico. Proporciona una base de datos robusta y de alta confianza para definir el perfil "ideal" o estándar de los granos de café de SenecaféAlpes.
- Este resultado impacta directamente en el objetivo de negocio de **Control de Calidad**, al permitir estandarizar la clasificación del producto basándose en evidencia morfológica.

Recomendaciones

1. Adoptar DBSCAN como Sistema de Control de Calidad.

- Acción: Usar el clúster principal para definir el perfil de grano "estándar".
- Aplicación: Analizar nuevos lotes para detectar y aislar automáticamente anomalías ("ruido"), asegurando la consistencia del producto.

2. Reservar K-Means para Segmentación Obligatoria.

- Condición: Utilizar K-Means solo si el negocio exige forzosamente dividir toda la producción en dos categorías definidas, como una línea "Estándar" y "Selecta".

